

Projekat: Predikcija cena letova

Opis problema

Cilj projekta je predikcija cene avionskog leta na osnovu dostupnih karakteristika leta, kao što su avio-kompanija, grad polaska, grad odredišta, vreme polaska i dolaska, broj presedanja, klasa leta, trajanje leta i broj dana preostalih do putovanja.

Ideja je da se sam problem predikcije cene u okviru projekta reši regresiono, dok bi potencijalno proširenje projekta podrazumevalo klasifikaciju na *BUY* ili *WAIT* kategoriju, to jest, da li se kupcu više isplati da kupi odmah kartu za let ili da čeka da cena padne.

Pregled kolona skupa podataka i njihovo značenje

Početni skup podataka je preuzet sa platforme Kaggle:

<https://www.kaggle.com/datasets/shubhambathwal/flight-price-prediction?resource=download>

Podaci koje ovaj skup nudi su:

- **Airline:** Naziv avio-kompanije - kategorijska karakteristika sa 6 različitih avio-kompanija (*Spicejet, AirAsia, Vistara, Indigo, Air_India, GO_FIRST*).
- **Flight:** Informacije o kodu leta aviona - kategorijska karakteristika.
- **Source City:** Grad iz kojeg avion poleće - kategorijska karakteristika sa 6 jedinstvenih gradova.
- **Departure Time:** Izvedena kategorijska karakteristika dobijena grupisanjem vremenskih perioda u intervale. Sadrži informacije o vremenu polaska i ima 6 jedinstvenih vremenskih oznaka (*Early_Morning, Morning, Afternoon, Evening, Night, Late_Night*).
- **Stops:** Kategorijska karakteristika sa 3 različite vrednosti koja čuva broj presedanja između polaznog i odredišnog grada (*zero, one, two_or_more*).
- **Arrival Time:** Izvedena kategorijska karakteristika dobijena grupisanjem vremenskih perioda u intervale. Sadrži informacije o vremenu dolaska i ima 6 jedinstvenih vremenskih oznaka (*Early_Morning, Morning, Afternoon, Evening, Night, Late_Night*).
- **Destination City:** Grad u koji avion sleće - kategorijska karakteristika sa 6 jedinstvenih gradova (*Mumbai, Chennai, Delhi, Bangalore, Kolkata, Hydebarad*).
- **Class:** Kategorijska karakteristika koja sadrži informacije o klasi sedišta; sa dve različite vrednosti: *Business* i *Economy*.
- **Duration:** Kontinuirana karakteristika koja prikazuje ukupno vreme putovanja između gradova izraženo u satima.
- **Days Left:** Izvedena karakteristika dobijena oduzimanjem datuma rezervacije od datuma putovanja.
- **Price:** Ciljna promenljiva koja sadrži informacije o ceni avionske karte.

Podaci će biti pretprocesirani pomoću odgovarajućih tehnika (regularizacija, normalizacija, skaliranje atributa, PCA...), a podela podataka na trening, test i validacioni skup obavljena po uzoru na primere dobre prakse.

Za proširenje projekta i poboljšanje njegove relevantnosti, kasnije će se potencijalno upotrebiti malo širi i uređeniji skup podataka, takođe preuzet sa interneta:

<https://data.mendeley.com/datasets/m5mvxdx2wp/2>

Očekivani izlaz

Kao izlaz očekuje se predviđena cena leta za regresioni problem, uz njegovu evaluaciju. Što se klasifikacionog problema tiče, očekivani izlaz je klasa *BUY* ili *WAIT*, takođe potkrepljena odgovarajućim metrikama.

Evaluacija regresionog problema podrazumeva prikaz rezultata kroz metrike *MAE* (radi intuitivnog razumevanja odstupanja), *RMSE* (radi kažnjavanja velikih grešaka i prikaza u istoj mernoj jedinici kao i ciljna promenljiva), kao i *R² score* (radi razumevanja celokupnog kvaliteta modela).

Metrike uzete za evaluaciju performansi klasifikacije bi bile *tačnost* i *F1 score* (podjednako su nam bitne i pozitivna i negativna greška). Priložena bi bila i matrica konfuzije.

Tumačenjem rezultata će se pokazati koji atribut ima najveći, a koji najmanji uticaj na varijabilnost cene, i zavisnost cene od tih atributa će biti prikazana grafički.

Dokumentovanje rezultata

Metričke vrednosti biće prikazane tabelarno. Grafičke analize uključivaće rang ulaznih parametara, potencijalno matricu konfuzije, kao i odnos predviđene i stvarne cene. Sve će biti formatirano tako da se može preneti u finalni Word izveštaj.

Krajnji zaključci i kritička analiza moraju se oslanjati na dobijene rezultate kroz poređenje različitih klasa algoritama: od linearnih i metričkih modela, zasnovanih na rastojanju, do ansambl metoda i stabala odlučivanja. Priložen će biti i opis korišćenih metoda pretprocesiranja podataka i podele na skupove za trening, test i validaciju.

Biće prokomentarisani karakteristični problemi nastali tokom izrade projekta, i kako su oni rešeni. Takođe, u radu će biti dat inženjerski osvrt na ponašanje modela, kao i konkretne smernice za dalju optimizaciju sistema, bilo kroz finije podešavanje hiperparametara, dodatnu obradu i modifikaciju feature-a iz postojećih podataka, ili uvođenje novih mernih veličina.